Taller 1

Diego Agamez, Karol Quemba, Martin Serna

Sistemas Avanzados de Producción

FREDY ALEXANDER ORJUELA LOPEZ

Universidad ECCI

2026

CONTENIDO

1 Estadıstica Descriptiva y Análisis Exploratorio

1.1 Caracterización Numérica

1.2 Análisis de Distribución y Atiıpico

1.2.1 Simetría de las distribuciones

1.2.2 Datos atípicos

1.3 Exploración de la Nube de Puntos

1.4 Evaluación de asociación

1.5 Interpretación de Resultados

2 Regresión Lineal y Diagnóstico

2.1 Modelamiento Múltiple

2.2 Interpretación de Parámetros

2.3 Análisis de bondad de ajuste

2.4 Estimación Matricial

3 Árboles de Decisión y Comparación de Modelos

3.1 entrenamiento del modelo

3.2 Representación Gráfica del Árbol

3.4Cálculo manual de incertidumbre

3.5 Importancia de predictores

1. Estadıstica Descriptiva y Análisis Exploratorio

1.1 Caracterización Numérica

Medidas de Tendencia Central y Dispersión

Variable	Media	Median a	Desv. Estándar	Mínimo	Máximo	Asimetría (Skewness)	Curtosis
TV	147.04	149.75	85.85	0.7	296.4	-0.07	-1.23
Radio	23.26	22.90	14.85	0.0	49.6	0.09	-1.26
Newspaper	30.55	25.75	21.78	0.3	114.0	0.89	0.65
Sales	14.02	12.90	5.22	1.6	27.0	0.41	-0.41

Tabla [1]: La tabla representa las medidas de tendencia central para las variables independientes y la dependiente

1.2 Análisis de Distribución y Atıpico

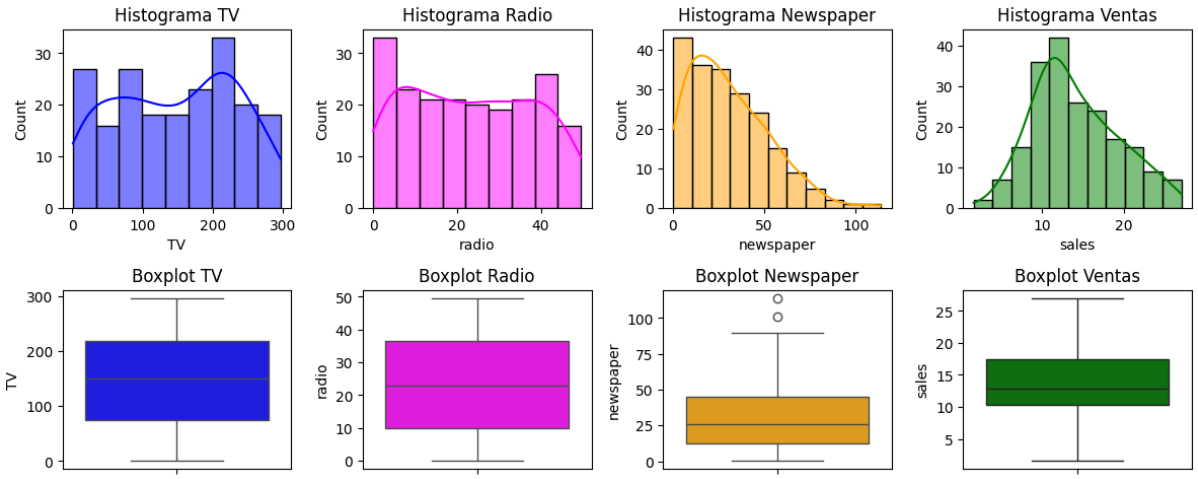

Figura [1]: La imagen presenta los histogramas y diagramas de caja de las variables inversión en publicidad en **TV**, **Radio** y **Newspaper**, junto con la variable **Ventas**. En la fila superior, los histogramas muestran la distribución de los datos: la inversión en TV presenta un rango amplio y distribución relativamente uniforme; Radio muestra una distribución equilibrada; Newspaper evidencia asimetría positiva con mayor concentración en valores bajos; y Ventas presenta una distribución cercana a normal. En la fila inferior, los boxplots permiten observar la mediana, dispersión y posibles valores atípicos, destacándose una mayor variabilidad en TV y Newspaper, mientras que Ventas y Radio presentan una dispersión más moderada.

1.2.1 Simetría de las distribuciones

Skewness ≈ 0 → Distribución simétrica

Skewness > 0 → Sesgo positivo (cola hacia la derecha)

Skewness < 0 → Sesgo negativo (cola hacia la izquierda)

Variable	Asimetría	Interpretación
TV	-0.07	Prácticamente simétrica
Radio	0.09	Muy leve sesgo positivo
Newspaper	0.89	Sesgo positivo moderado
Sales	0.41	Sesgo positivo leve

Tabla 2: presenta el coeficiente de asimetría de las variables TV, Radio, Newspaper y Sales. Se observa que la variable TV (-0.07) presenta una distribución prácticamente simétrica, lo que indica una distribución equilibrada alrededor de la media.

1.2.2 Datos atípicos

En los diagramas de caja se observa que TV, Radio y Sales no presentan valores atípicos significativos, ya que no aparecen puntos fuera de los bigotes o estos son mínimos y no extremos. Sin embargo, en Newspaper sí se identifican valores atípicos en la parte superior, lo que indica la presencia de algunas observaciones con inversión considerablemente mayor que la mayoría de los datos. Estos valores atípicos pueden influir en un modelo de regresión al modificar la pendiente de la recta, afectar el intercepto y aumentar el error del modelo, especialmente si son puntos influyentes. En particular, los valores altos en Newspaper podrían hacer que se sobreestime o subestime su efecto real sobre las Sales, alterando la precisión y estabilidad del modelo predictivo.

1.3 Exploración de la Nube de Puntos

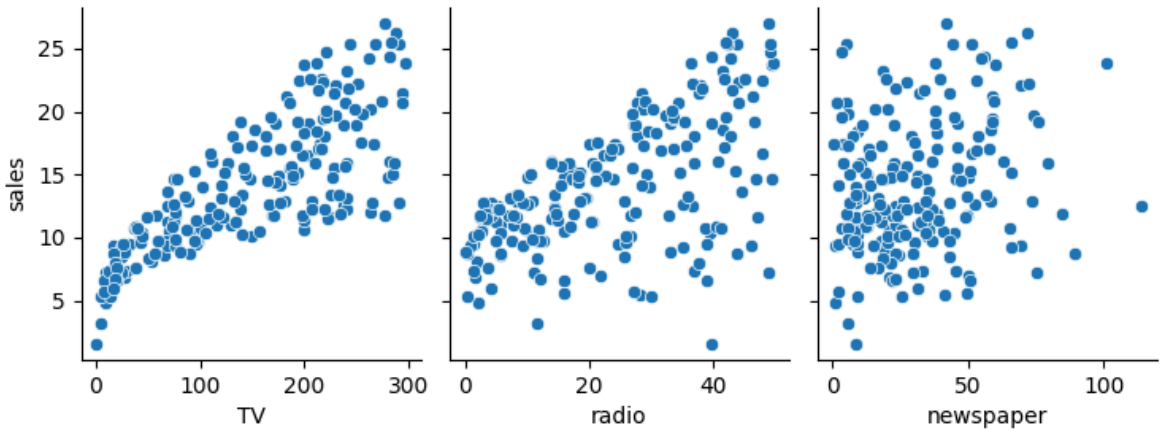

Figura (3)

En el caso de Sales vs TV, la nube de puntos muestra una tendencia claramente ascendente y bastante alineada, lo que sugiere una relación lineal positiva fuerte. Los puntos siguen una forma cercana a una línea recta creciente, sin evidenciar curvaturas pronunciadas ni patrones parabólicos. Esto indica que a mayor inversión en televisión, mayores son las ventas, manteniendo un comportamiento relativamente estable.

Para Sales vs Radio, también se observa una tendencia positiva. Sin embargo, la dispersión de los puntos es un poco mayor en comparación con TV. Aun así, la nube mantiene una forma aproximadamente lineal creciente, lo que sugiere una relación lineal moderada entre la inversión en radio y las ventas.

En contraste, en el gráfico de Sales vs Newspaper, la nube de puntos se encuentra mucho más dispersa y no se observa una dirección clara o una alineación definida. No se identifican patrones curvos evidentes, pero tampoco una tendencia lineal fuerte. Esto sugiere que la relación entre la inversión en prensa escrita y las ventas es débil, y no parece seguir un patrón lineal significativo.

En general, no se evidencian formas parabólicas ni segmentos definidos en los gráficos. Tampoco se observan puntos extremadamente alejados que indiquen datos altamente influyentes. Por lo tanto, visualmente se concluye que las relaciones de Sales con TV y Radio pueden modelarse adecuadamente mediante un modelo lineal simple, mientras que Newspaper no muestra una relación clara con la variable respuesta.

1.4 Evaluación de asociación

Pearson

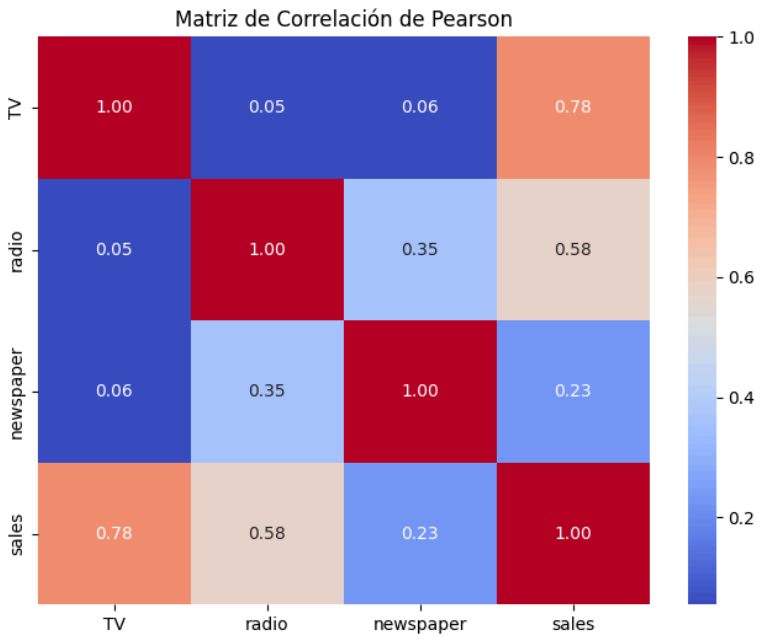

Figura (4)

Spearman

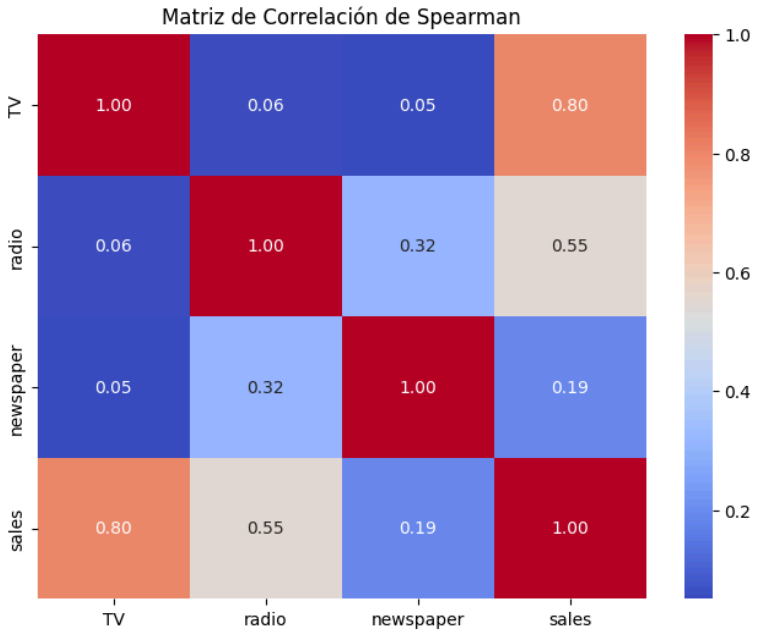

Figura (5)

SALES vs TV: A partir de la matriz de correlación de **Pearson** encontramos un valor de **0.78** entre las variables *Sales* y la publicidad invertida en *TV*, lo que indica una correlación **positiva y alta**. De igual manera, en la matriz de **Spearman** se obtiene un valor de **0.80**, confirmando una relación positiva fuerte. Esto significa que, a mayor inversión en televisión, mayores son las ventas, evidenciando que TV es el medio publicitario con mayor impacto sobre las ventas.

SALES vs Radio: En la matriz de **Pearson** se observa una correlación de **0.58**, lo que representa una relación **positiva moderada**. Por su parte, en **Spearman** el

valor es **0.55**, manteniendo una relación positiva similar. Esto indica que la inversión en radio también influye en las ventas, aunque en menor proporción que la televisión.

SALES vs Newspaper: En la matriz de **Pearson** se obtiene un valor de **0.23**, mostrando una correlación **positiva baja**. En **Spearman**, el coeficiente es **0.19**, lo que confirma que la relación es débil. Esto sugiere que la inversión en prensa escrita tiene poca influencia sobre las ventas en comparación con TV y Radio.

Las dos matrices (Pearson y Spearman) presentan resultados muy similares, lo que indica consistencia en la relación entre las variables. La publicidad en **TV** es el elemento con mayor correlación con las ventas, seguida de **Radio**, mientras que **Newspaper** presenta la menor influencia. Esto sugiere que, estratégicamente, la inversión debería priorizarse en televisión para maximizar el impacto en las ventas.

1.5 Interpretación de Resultados

¿Qué significa un coeficiente cercano a 1 o −1 en el contexto de la inversión publicitaria y el retorno en ventas?

Un coeficiente de correlación cercano a 1 indica una relación positiva muy fuerte, es decir, que a medida que aumenta la inversión publicitaria, las ventas también aumentan de manera proporcional y consistente. En este contexto, significa que el medio publicitario es altamente efectivo para generar retorno en ventas. Por el contrario, un coeficiente cercano a −1 indicaría una relación negativa muy fuerte, lo que implicaría que al aumentar la inversión las ventas disminuyen, situación poco lógica en este caso, pero estadísticamente posible.

2. ¿Cómo se interpreta un valor de correlación cercano a 0?

Un valor de correlación cercano a 0 indica que no existe una relación lineal significativa entre la inversión publicitaria y las ventas. Esto significa que los cambios en la inversión no están asociados de forma clara con aumentos o disminuciones en las ventas. En el análisis realizado, Eso pasa con Newspaper (periódico), que tiene números bajos (0.23 y 0.19). Eso quiere decir que invertir en periódico casi no afecta las ventas.

3. Compare ambos coeficientes (Pearson y Spearman). ¿Sugieren estos resultados que las relaciones son estrictamente lineales? Justifique su respuesta basándose en la forma de la nube de puntos observada.

Al comparar los coeficientes de Pearson y Spearman, se observa que los valores son muy similares en todas las variables (por ejemplo, TV con 0.78 en Pearson y

0.80 en Spearman). Esto indica que las relaciones no solo son lineales, sino también monotónicas (mantienen una tendencia creciente consistente).

Dado que ambos coeficientes presentan resultados cercanos, se puede inferir que la relación entre inversión en TV y ventas es predominantemente lineal. En la nube de puntos se observa una tendencia ascendente clara, donde los datos siguen un patrón aproximadamente alineado, aunque con cierta dispersión natural. No obstante, como los valores no son exactamente 1, esto indica que la relación no es perfectamente lineal, sino fuerte pero con variabilidad. Los resultados sugieren que existe una relación mayormente lineal, especialmente en el caso de TV y Radio, mientras que Newspaper no presenta una relación lineal significativa.

2. Regresión Lineal y Diagnóstico

2.1 Modelamiento Múltiple

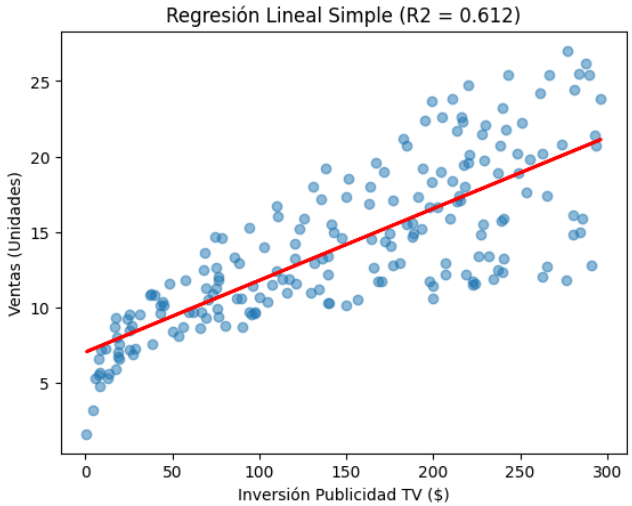

Figura (6): Se observa una relación positiva y fuerte entre la inversión en televisión y las ventas. El valor de R^2 indica que aproximadamente el 61.2% de la variación en las ventas se explica por la inversión en TV, lo que la convierte en la variable con mayor capacidad predictiva individual.

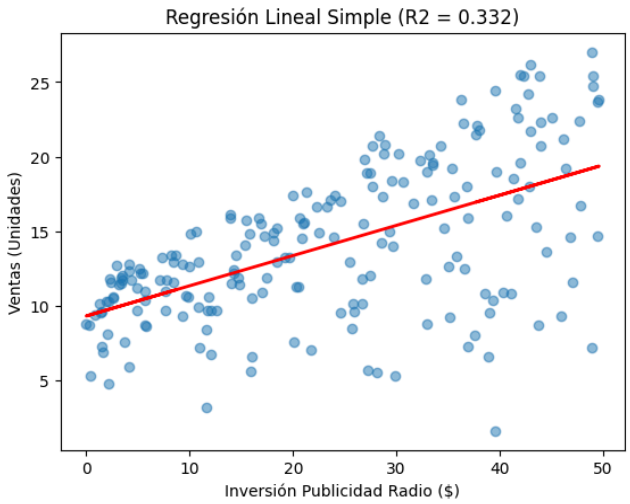

Figura (7): También presenta una relación positiva, pero más moderada. El modelo explica cerca del 33.2% de la variabilidad en las ventas, lo que indica que la radio influye en las ventas, aunque en menor proporción que la televisión.

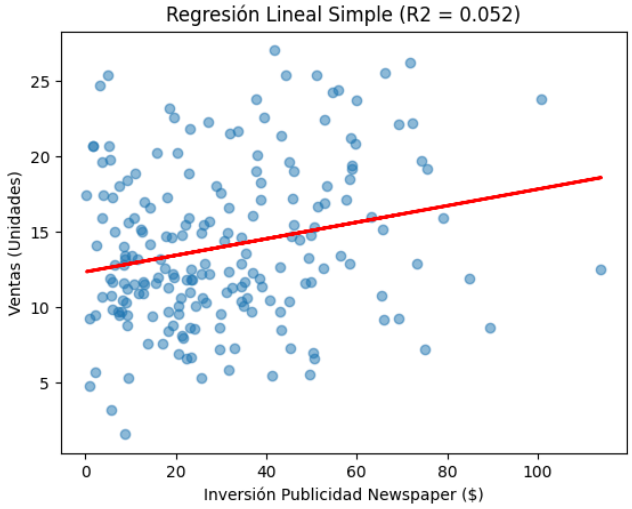

Figura (8): La relación es positiva pero muy débil. El valor de R^2 muestra que solo el 5.2% de la variación en las ventas se explica por la inversión en prensa, lo que sugiere que esta variable tiene poca influencia en comparación con TV y Radio.

2.2 Interpretación de Parámetros

Variable	Asimetría	Interpretación
β_0	Sales (Intercepto)	2.9389
β_1	TV	0.0458
β_2	Radio	0.1885
β_3	Newspaper	-0.0010

Tabla (3)

β_0 (Intercepto) = 2.9389
Este valor significa que, aunque no se invierta nada en TV, Radio o Newspaper, las ventas serían aproximadamente **2.94 unidades**. Es como el punto de partida de las ventas sin publicidad.

β_1 (TV) = 0.0458
Esto significa que por cada unidad adicional que se invierte en TV, las ventas aumentan en **0.0458 unidades**, manteniendo todo lo demás constante.
Es un efecto positivo, lo que confirma que la televisión sí ayuda a aumentar las ventas.

β_2 (Radio) = 0.1885
Por cada unidad adicional invertida en Radio, las ventas aumentan en **0.1885 unidades**.
Este número es mayor que el de TV, lo que indica que, en el modelo, la radio tiene un impacto más fuerte por cada unidad invertida.

β_3 (Newspaper) = −0.0010
Este valor es prácticamente cero y además es negativo. Esto significa que invertir en Newspaper casi no cambia las ventas, e incluso podría disminuirlas ligeramente, pero el efecto es tan pequeño que se considera insignificante.

2.3 Análisis de bondad de ajuste

Variable Independiente	R^2	Variabilidad Explicada
TV	0.612	61.2%
Radio	0.332	33.2%
Newspaper	0.052	5.2%

Tabla (4)

La tabla muestra la proporción de la variabilidad total de las ventas que es explicada por cada modelo simple. Se observa que TV tiene el mayor poder explicativo, seguida por Radio, mientras que Newspaper presenta una capacidad explicativa muy baja.

Al comparar con el modelo múltiple, la inclusión de Radio sí mejora el ajuste respecto al modelo simple inicial, ya que aporta capacidad explicativa adicional. Sin embargo, la variable Newspaper no contribuye de manera significativa al ajuste debido a su bajo poder explicativo individual. En conclusión, el modelo mejora principalmente gracias a la combinación de TV y Radio, mientras que Newspaper aporta muy poco a la explicación de las ventas.

2.4 Estimación Matricial

$$X = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix} \qquad Y = \begin{pmatrix} 2 \\ 4 \\ 6 \\ 7 \\ 9 \end{pmatrix}$$

Transpuesta

$$X' = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix}$$

Producto $X'X$

$1+1+1+1+1 = 5$

$1+2+3+4+5 = 15$

$1^2+2^2+3^2+4^2+5^2 = 55$

$$X'X = \begin{pmatrix} 5 & 15 \\ 15 & 55 \end{pmatrix}$$

Inversa

$$Det = (5 \cdot 55) - (15 \cdot 15) = 275 - 225 = 50$$

$$(X'X)^{-1} = \frac{1}{50}\begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix} = \begin{pmatrix} 1{,}1 & -0{,}3 \\ -0{,}3 & 0{,}1 \end{pmatrix}$$

Producto

$X'Y$

$2+4+6+7+9 = 28$

$(1 \cdot 2)+(1 \cdot 4)+(3 \cdot 6)+(4 \cdot 7)+(5 \cdot 9) = 100$

$$X'Y = \begin{pmatrix} 28 \\ 100 \end{pmatrix}$$

$$\hat{\beta} = \begin{pmatrix} 1{,}1 & -0{,}3 \\ -0{,}3 & 0{,}1 \end{pmatrix}\begin{pmatrix} 28 \\ 100 \end{pmatrix}$$

$$\hat{\beta}_0 = (1{,}1 \cdot 28) + (-0{,}3 \times 100) = 30{,}8 - 30 = 0{,}8$$

$$\hat{\beta}_1 = (-0{,}3 \cdot 28) + (0{,}1 \times 100) = -8{,}4 + 10 = 1{,}60$$

$$\hat{y} = 0{,}80 + 1{,}60x$$

	TV	Radio	Newspaper	Sales
TV	7370.9499	69.8625	105.9195	350.3902
Radio	69.8625	220.4277	114.4970	44.6357
Newspaper	105.9195	114.4970	474.3083	25.9414
Sales	350.3902	44.6357	25.9414	27.2219

Tabla(5) : Esta tabla muestra la covarianza entre las variables. Se observa que TV y Sales tienen una covarianza alta (350.39), lo que indica una relación positiva fuerte. Radio también tiene relación positiva con Sales, pero menor. Newspaper presenta la covarianza más baja con Sales, lo que sugiere menor influencia.

	TV	Radio	Newspaper	Sales
TV	1.0000	0.0548	0.0566	0.7822
Radio	0.0548	1.0000	0.3541	0.5762
Newspaper	0.0566	0.3541	1.0000	0.2283
Sales	0.7822	0.5762	0.2283	1.0000

Tabla(6): Esta matriz muestra la correlación lineal entre variables. La mayor correlación con Sales es la de TV (0.7822), seguida de Radio (0.5762). Newspaper tiene una correlación baja (0.2283), lo que indica poca relación con las ventas.

	TV	Radio	Newspaper	Sales
TV	1.0000	0.0561	0.0508	0.8006
Radio	0.0561	1.0000	0.3170	0.5543
Newspaper	0.0508	0.3170	1.0000	0.1949
Sales	0.8006	0.5543	0.1949	1.0000

Tabla(7): Los resultados son muy similares a la tabla anterior. Nuevamente, TV es la variable más relacionada con Sales (0.8006), Radio mantiene una relación moderada y Newspaper sigue mostrando una relación débil. Esto confirma que la televisión es el medio con mayor impacto en las ventas.

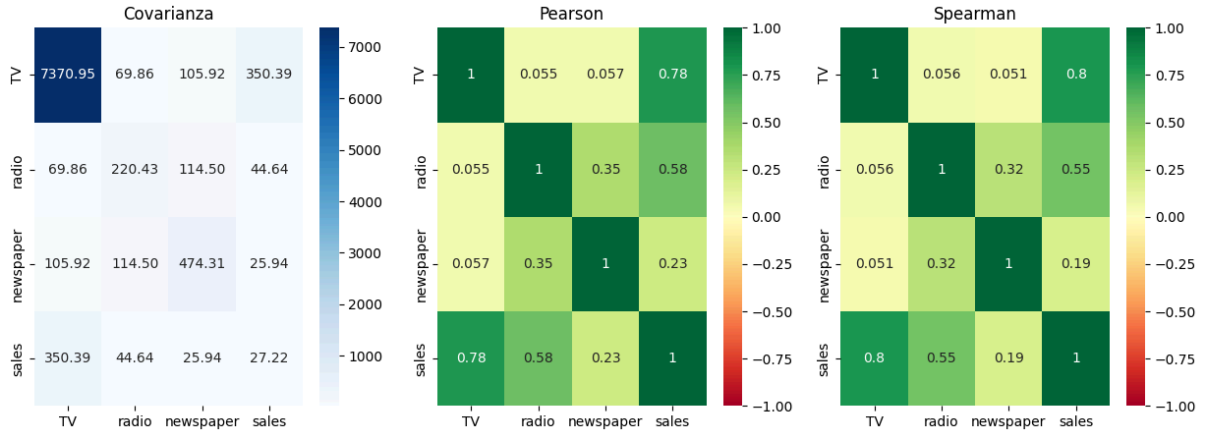

Figura (9): La imagen presenta tres matrices (Covarianza, Pearson y Spearman) que analizan la relación entre medios publicitarios y ventas. Se observa una fuerte correlación positiva de las ventas con la TV y el radio, mientras que el periódico muestra el impacto más débil. Estas gráficas confirman que la inversión en televisión es el motor principal de resultados en este conjunto de datos.

3 Árboles de Decisión y Comparación de Modelos

3.1 entrenamiento del modelo

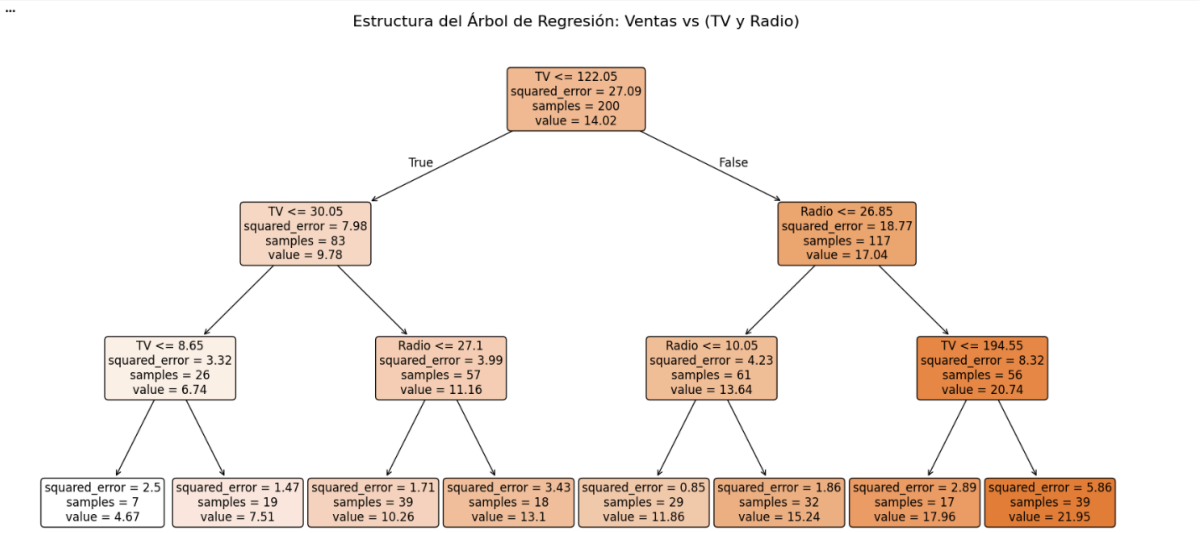

Figura (10)

Para el desarrollo del modelo predictivo se entrenó un Árbol de Regresión, utilizando como variables independientes la inversión publicitaria en TV y Radio, con el objetivo de predecir el comportamiento de las ventas (Sales).

El entrenamiento del modelo consiste en analizar los datos históricos y generar divisiones sucesivas que permitan reducir el error de predicción en cada etapa del proceso.

Estructura del Árbol de Decisión

El árbol obtenido presenta una estructura jerárquica donde cada nodo representa una regla de decisión basada en valores umbral de las variables analizadas.

La primera partición del modelo se realiza bajo la condición:

TV≤122.05TV

Esta división inicial indica que la inversión en televisión es la variable con mayor capacidad explicativa sobre las ventas, por lo cual el algoritmo la selecciona como criterio principal de segmentación.

A partir de esta división, el modelo genera dos grandes grupos:

- Escenarios con baja o media inversión en TV
- Escenarios con alta inversión en TV

Posteriormente, el árbol introduce nuevas particiones utilizando tanto la variable TV como Radio, permitiendo refinar la predicción de ventas en cada subconjunto de datos.

Criterio de Partición en los Nodos

Las particiones del árbol se realizan mediante la minimización del error cuadrático medio (Squared Error).

El algoritmo evalúa múltiples posibles divisiones y selecciona aquella que:

Reduce al máximo la variabilidad de las ventas dentro de cada nodo
Genera grupos más homogéneos
Mejora la precisión de la predicción

Interpretación del Entrenamiento

El análisis del árbol muestra que:

- La inversión en TV determina inicialmente el nivel general de ventas.
- La Radio actúa como variable complementaria que ajusta la predicción dentro de cada segmento.
- Los mayores valores de ventas se presentan cuando ambas inversiones alcanzan niveles elevados.

Desde el enfoque de Ingeniería Industrial, este proceso permite identificar rangos óptimos de inversión publicitaria y comprender cómo diferentes combinaciones de recursos influyen en el desempeño comercial.

3.2 Representación Gráfica del Árbol

La gráfica del árbol de regresión muestra:

- Nodos internos → reglas de decisión (TV o Radio).
- Ramas → resultado verdadero o falso de la condición.
- Nodos hoja → valor estimado de ventas.
- Squared Error → nivel de error dentro del grupo.
- Samples → cantidad de observaciones analizadas.

Esta representación facilita la interpretación visual del modelo y apoya la toma de decisiones basada en datos.

Variable	Importancia en el Árbol	Coeficiente Regresión
TV	0.6425	0.0458
Radio	0.3575	0.1880

Tabla (8): Esta tabla compara los resultados de ambos modelos, destacando que el Árbol de Decisión asigna a la TV la mayor importancia (64.25%) frente al Radio (35.75%), mientras que la Regresión Lineal muestra una tendencia opuesta al otorgar un coeficiente mayor al Radio (0.1880) que a la TV (0.0458).

Modelo Estadístico	**TV**	**Radio**	**Interpretación Técnica**

Árbol de Decisión (Importancia de la variable)	64.25 %	35.75 %	En el modelo de árbol de decisión, la variable TV presenta una importancia relativa del 64.25%, considerablemente superior al 35.75% de Radio. Esto indica que, desde una perspectiva no lineal y de segmentación, la inversión en televisión es el factor con mayor poder predictivo y explicativo sobre el comportamiento de las ventas.
Regresión Lineal (Coeficiente no estandarizado)	0.0458	0.1880	Contrario al resultado del árbol, el modelo de regresión lineal otorga un coeficiente mayor a la variable Radio (0.1880), en comparación con TV (0.0458). Esto sugiere que, bajo el supuesto de linealidad, Radio posee un mayor impacto marginal; es decir, por cada unidad monetaria adicional invertida en este canal, el incremento esperado en las ventas es superior al que generaría la misma inversión en televisión.

Tabla (9): Esta tabla explica que el Árbol de Decisión prioriza la TV por su gran poder predictivo y capacidad de segmentación no lineal, mientras que la Regresión Lineal sugiere que el Radio tiene un impacto marginal más eficiente, lo que implica que cada unidad monetaria extra invertida en radio genera un retorno en ventas superior al de la televisión.

3.4 Cálculo manual de incertidumbre

Concepto	Detalle / Cálculo	Valor
Nodo Padre	**3 Éxitos, 1 Falla (Total: 4)**	**-**
Producto Tipo A	**2 Éxitos, 0 Fallas (Total: 2)**	**-**
Producto Tipo B	**1 Éxito, 1 Falla (Total: 2)**	**-**

Entropía (Nodo Padre)	**Medida de incertidumbre inicial**	**0.8113**
Índice Gini (Nodo Padre)	**Medida de impureza inicial**	**0.3750**

Tabla (10): Esta tabla establece el punto de partida del análisis. Describe la composición del Nodo Padre (el total de datos antes de dividir) y calcula su Entropía y Gini. Estas métricas miden qué tan "mezclados" o impuros están los éxitos y fallas originalmente.

Grupo de Producto	Métrica de Entropía	Métrica de Índice Gini
Producto Tipo A	**0.0000**	**0.0000**
Producto Tipo B	**1.0000**	**0.5000**

Tabla (11): Muestra la efectividad de dividir los datos según el tipo de producto. Al separar en "Tipo A" y "Tipo B", vemos que el Tipo A alcanza una pureza total (Entropía 0), mientras que el Tipo B permanece totalmente incierto (Entropía 1), lo que ayuda a entender qué tan buena es esa variable para predecir el resultado.

Métrica de Ganancia	Descripción	Resultado
Entropía Promedio Ponderada	**Promedio de entropía de los hijos**	**0.5000**
Ganancia de Información	**Reducción total de la entropía**	**0.3113**

Tabla (12): Es la métrica de decisión principal para el árbol. Calcula cuánto "orden" ganamos al hacer la división. Una Ganancia de Información de 0.3113 indica cuánto se redujo la incertidumbre inicial del nodo padre tras aplicar el filtro de tipo de producto.

Variable	Importancia en el Árbol	Coeficiente de Regresión
TV	**0.6425**	**0.0458**
Radio	**0.3575**	**0.1880**

Tabla (13): Esta tabla pone frente a frente dos enfoques: el Árbol de Decisión (que mide la importancia por pureza) y la Regresión Lineal (que mide por coeficientes de peso). Permite observar que, aunque ambos modelos analizan TV y Radio, el árbol le da un peso dominante a TV (0.64), mientras que la regresión asigna un impacto distinto a cada variable.

Concepto	Product Type A	Product Type B	Total / Promedio
Distribución (Éxito / Fracaso)	2 Success, 0 Failure	1 Success, 1 Failure	**Parent Node:** 3 Success, 1 Failure
Total de muestras por nodo	2	2	**Parent Node:** 4
Entropía del nodo	0.0000	1.0000	**Parent Node:** 0.8113
Índice Gini	0.0000	0.5000	**Parent Node:** 0.3750
Ganancia de Información	—	—	**0.3113**

Tabla (14):

- Product Type A es un nodo perfectamente puro (entropía y Gini = 0). Esto significa que todos los casos en esta categoría resultaron en "Éxito". Es una regla de decisión confiable.

- Product Type B presenta máxima impureza (entropía = 1, Gini = 0.5), con un caso de éxito y uno de fracaso. Esto indica que la variable *Product Type* no es suficiente para clasificar correctamente los casos de esta categoría.
- La Ganancia de Información de 0.3113 indica que dividir por esta variable reduce la incertidumbre inicial en un 38.4%, lo que la convierte en un buen predictor inicial, aunque se requieren variables adicionales para segmentar *Product Type B*.

3.5 Importancia de predictores

En el análisis realizado con Regresión Lineal, Árbol de Decisión y Random Forest se evaluó la influencia de “TV” y “Radio” en la predicción de ventas. Los modelos basados en árboles, muestran resultados muy similares: ambos asignan mayor importancia a la variable TV, con valores cercanos al 64–65%, mientras que Radio se ubica entre 35–36%. Esto indica que, desde una perspectiva estructural, la inversión en televisión es el factor que más pesa al momento de explicar la variabilidad de las ventas.

Sin embargo, la Regresión Lineal ofrece una visión distinta. En este modelo, el coeficiente de Radio (0.1880) es considerablemente mayor que el de TV (0.0458), lo que significa que, por cada unidad adicional de inversión, Radio genera un incremento marginal más alto en ventas que TV. Es decir, aunque TV tenga mayor peso global en los modelos de árboles, Radio parece ser más eficiente por unidad invertida cuando se analiza el impacto directo y lineal.

Esta diferencia se explica por la naturaleza de los modelos. Los árboles priorizan las variables que permiten dividir mejor los datos y reducir el error, enfocándose en la estructura de decisión. En cambio, la Regresión Lineal mide el efecto constante e independiente de cada variable, asumiendo una relación lineal y sin considerar interacciones complejas o puntos de corte.

En conclusión, desde el enfoque de segmentación y estructura (Árbol de Decisión y Random Forest), la TV es el factor principal en la predicción de ventas. No obstante, desde la perspectiva de eficiencia marginal (Regresión Lineal), la Radio muestra un mayor rendimiento por unidad invertida. Esto demuestra que distintos modelos pueden ofrecer interpretaciones complementarias y que la decisión final debe considerar ambos enfoques para tener una visión más completa.

se analizan los resultados comparativos de la importancia de las variables *TV* y *Radio* en la predicción de ventas, evaluadas mediante tres modelos: Árbol de Decisión Único, Random Forest y Regresión Lineal

Análisis de Resultados

1. Consistencia entre modelos de árbol: Tanto el Árbol de Decisión Único como el Random Forest asignan una importancia dominante a la variable *TV*, con valores de 64.25% y 64.66% respectivamente. Esta consistencia indica que, desde la perspectiva de modelos no lineales basados en particiones, la inversión en televisión es el factor con mayor capacidad predictiva sobre las ventas. La variable *Radio* presenta una importancia secundaria y estable, cercana al 35% en ambos modelos.
2. Divergencia con el modelo lineal: La Regresión Lineal muestra un resultado contrastante. El coeficiente de *Radio* (0.1880) es notablemente superior al de *TV* (0.0458). Esto sugiere que, bajo el supuesto de linealidad, cada unidad monetaria adicional invertida en *Radio* genera un retorno marginal sobre las ventas aproximadamente cuatro veces mayor que la misma inversión en *TV*.
3. Explicación de la divergencia: Esta diferencia se debe a la naturaleza de cada modelo:
    - Los modelos de árbol evalúan la importancia de una variable midiendo cuánto reduce la impureza en cada división, lo que les permite capturar relaciones no lineales, interacciones y efectos umbral.
    - La regresión lineal mide el impacto lineal y constante de cada variable, asumiendo relaciones aditivas y sin considerar interacciones complejas.

Diagnóstico comparativo

La elección entre un modelo de regresión lineal y un árbol de decisión depende principalmente del nivel de interpretabilidad requerido y del comportamiento de los datos.

La regresión lineal es preferible en escenarios donde se busca comprender con precisión el efecto de cada variable independiente sobre la variable dependiente. Este modelo permite cuantificar de manera directa cuánto cambia el resultado ante una variación en un predictor, lo cual facilita la justificación técnica y la toma de decisiones basadas en datos. Además, presenta un buen desempeño cuando la relación entre las variables es aproximadamente lineal y cuando se requiere realizar estimaciones fuera del rango de los datos observados.

Por su parte, el árbol de decisión resulta más adecuado cuando las relaciones entre variables son no lineales o cuando existen interacciones complejas que no pueden modelarse fácilmente mediante una ecuación lineal. En estos casos, puede ofrecer mayor precisión en el pronóstico, ya que segmenta los datos en grupos más específicos. Sin embargo, aunque su estructura es intuitiva y fácil de interpretar

visualmente, no permite medir de forma numérica y directa el impacto individual de cada variable.

En conclusión, si el objetivo principal es la claridad en la interpretación y la explicación del modelo, la regresión lineal es la opción más conveniente. En cambio, si se prioriza la capacidad predictiva en escenarios complejos, el árbol de decisión puede ser una alternativa más apropiada.

Tareas 1 ,2 , 3

Nodo Padre (antes de dividir):

- Total de muestras: 10
- Éxitos (ventas altas): 6
- Fracasos (ventas bajas): 4

$$p_{\text{éxito}} = \frac{6}{10} = 0.6, \quad p_{\text{fracaso}} = \frac{4}{10} = 0.4$$

---

1. Entropía del Nodo Padre

$$H(S) = -\sum p_i \log_2(p_i)$$

$$H(S) = -[0.6 \cdot \log_2(0.6) + 0.4 \cdot \log_2(0.4)]$$

Sabemos:

$$\log_2(0.6) \approx -0.736, \quad \log_2(0.4) \approx -1.322$$

$$H(S) = -[0.6 \cdot (-0.736) + 0.4 \cdot (-1.322)]$$

$$H(S) = -[-0.4416 - 0.5288] = -[-0.9704] = 0.9704$$

Entropía del nodo padre:

$$\boxed{0.9704}$$

---

2. Índice de Gini del Nodo Padre

$$\text{Gini} = 1 - \sum p_i^2$$

$$\text{Gini} = 1 - (0.6^2 + 0.4^2) = 1 - (0.36 + 0.16) = 1 - 0.52 = 0.48$$

Índice de Gini del nodo padre:

$$\boxed{0.48}$$

3. Ganancia de Información al dividir por "Inversión TV"

Paso 1 – Entender los datos de la división:

La variable **Inversión TV** divide las 10 muestras en dos grupos:

- **TV Alta:** 6 muestras → 5 ventas altas (éxito) y 1 venta baja (fracaso)
- **TV Baja:** 4 muestras → 1 venta alta (éxito) y 3 ventas bajas (fracaso)

Paso 2 – Calcular la entropía de cada grupo:

Grupo TV Alta:

- Probabilidad de éxito: 5/6 = 0.833
- Probabilidad de fracaso: 1/6 = 0.167

Fórmula:

$$H = -(p_{éxito} \cdot \log_2(p_{éxito}) + p_{fracaso} \cdot \log_2(p_{fracaso}))$$

$$H_{Alta} = -(0.833 \cdot (-0.263) + 0.167 \cdot (-2.585))$$

$$H_{Alta} = -(-0.219 - 0.432) = -(-0.651) = 0.651$$

Grupo TV Baja:

- Probabilidad de éxito: 1/4 = 0.25
- Probabilidad de fracaso: 3/4 = 0.75

$$H_{Baja} = -(0.25 \cdot (-2) + 0.75 \cdot (-0.415))$$

$$H_{Baja} = -(-0.5 - 0.311) = -(-0.811) = 0.811$$

Paso 3 – Calcular la entropía promedio ponderada:

Se pondera según la cantidad de muestras en cada grupo:

$$H_{ponderada} = \left(\frac{6}{10} \cdot 0.651\right) + \left(\frac{4}{10} \cdot 0.811\right)$$

$$H_{ponderada} = (0.6 \cdot 0.651) + (0.4 \cdot 0.811)$$

$$H_{ponderada} = 0.3906 + 0.3244 = 0.715$$

Paso 4 – Calcular la Ganancia de Información:

La entropía del nodo padre (antes de dividir) era:

$$H_{padre} = 0.9704$$

La ganancia de información es lo que se reduce la entropía al dividir:

$$IG = H_{padre} - H_{ponderada}$$

$$IG = 0.9704 - 0.715 = 0.2554$$

Resultado final:

$$\boxed{0.2554}$$

Esto significa que dividir por la variable **Inversión TV** reduce la incertidumbre en 0.2554, lo que ayuda a clasificar mejor los datos.