Taller 2: Redes Neuronales

Diego Agamez, Karol Quemba, Martin Serna

Sistemas Avanzados de Producción

FREDY ALEXANDER ORJUELA LOPEZ

Universidad ECCI 2026

FASE 1

Sobre la Invertibilidad

¿Porque la suma de λ garantiza que la matriz resultante sea invertible incluso si X^T X es singular (no invertible)?

En problemas de alta dimensionalidad o multicolinealidad, la matriz X^T X puede ser singular (tener determinante cero o valores propios iguales a cero). Al sumar λ (donde λ > 0), estamos sumando una cantidad positiva a todos los valores propios de la matriz original. Esto desplaza los valores propios lejos del cero, asegurando que la matriz resultante sea definida positiva y, por lo tanto, siempre invertible.

Efecto del Parámetro λ

¿Qué sucede con el modelo y sus coeficientes cuando ? ¿Y qué ocurre cuando λ → ∞? Explique en términos de la complejidad del modelo (Sesgo y. Varianza).

Cuando λ → 0: La penalización desaparece. El estimador Ridge converge al estimador de Mínimos Cuadrados Ordinarios (OLS). El modelo tiene baja propensión al sesgo pero alta varianza (tiende al sobreajuste o *overfitting*).

Cuando λ → ∞: La penalización se vuelve dominante. Para que el costo no sea infinito, los coeficientes β deben aproximarse a cero.

Sesgo vs. Varianza: Al aumentar λ, estamos introduciendo deliberadamente un poco de sesgo en las estimaciones a cambio de una reducción significativa en la varianza. Esto suele mejorar la capacidad de generalización del modelo en datos nuevos.

FASE 2
Impacto de la Tasa de Aprendizaje

Learning_rate: 0.0001

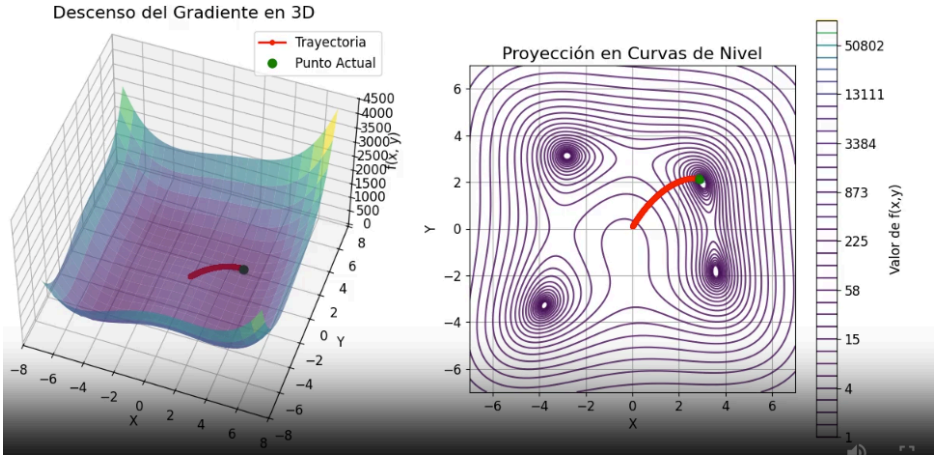

Imagen 1 (Fuente: elaboración propia con base en el notebook del curso.)

Learning_rate: 0.6

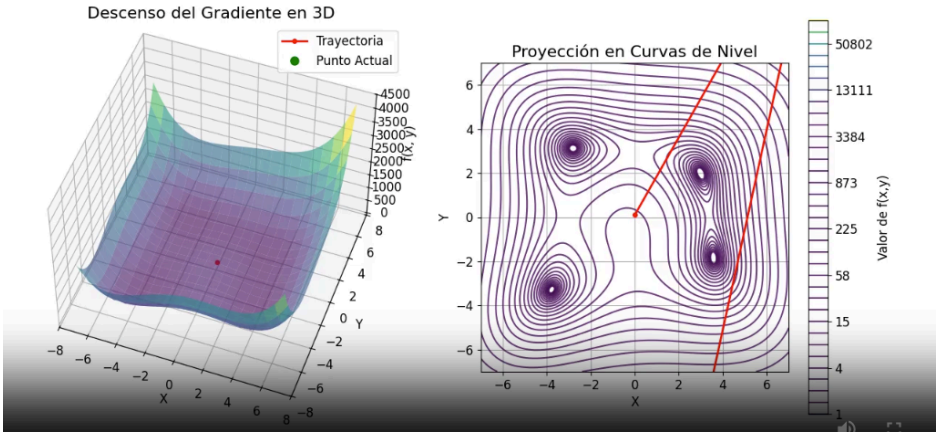

Imagen 2 (Fuente: elaboración propia con base en el notebook del curso.)

Learning_rate: 0.000000008

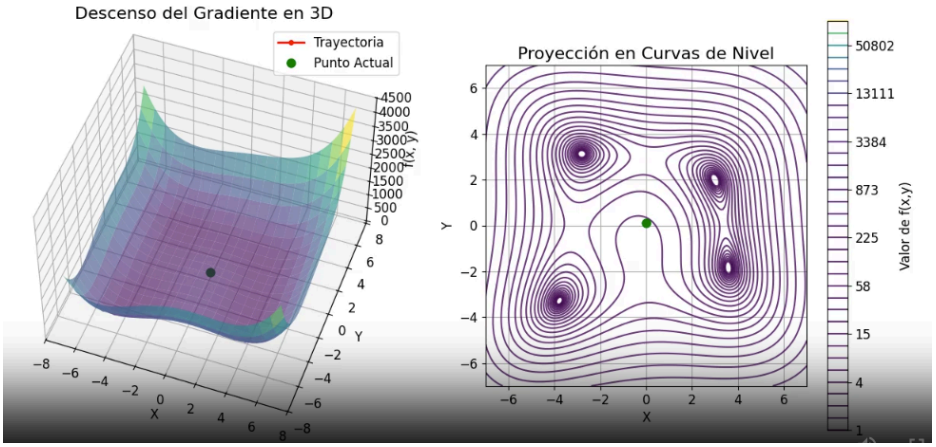

Imagen 3 (Fuente: elaboración propia con base en el notebook del curso.)

Estas tres simulaciones muestran cómo el Learning Rate determina la capacidad del modelo para encontrar el punto más bajo (mínimo) de la función de pérdida. En la primera imagen (0.0001), el ritmo es adecuado, permitiendo que el punto descienda de forma fluida y controlada hacia el objetivo. En cambio, con un valor de 0.6, el paso es demasiado grande, lo que provoca que el algoritmo "rebote" y diverge, alejándose por completo del área de interés. Por último, con un valor de 0.000000008, el avance es excesivamente lento; el punto parece estático porque el "paso" es tan minúsculo que el modelo tardaría una eternidad en converger, lo que lo hace computacionalmente ineficiente.

Dependencia del Punto Inicial

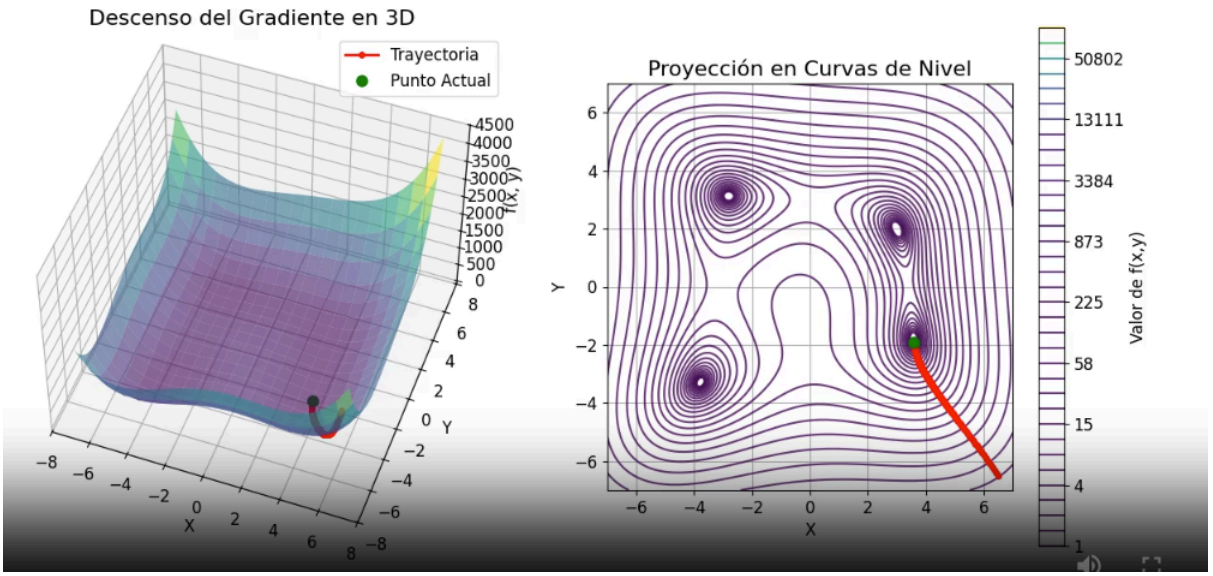

Imagen 4 (Fuente: elaboración propia con base en el notebook del curso.)

No, el algoritmo no llega siempre al mismo punto final, al cambiar las coordenadas del punto inicial el modelo busca el mínimo más cercano. Al observar el gráfico de curvas de nivel, se nota claramente que la función f(X,Y) no es convexa, ya que presenta múltiples valles o mínimos locales pues se ven al menos cuatro círculos cerrados en la gráfica.

El fenómeno de “Overshooting”: Explique físicamente qué ocurre cuando el paso ($\eta \cdot \nabla f$) es más grande que la distancia al mínimo. ¿Cómo se visualiza esto en el gráfico de curvas de nivel?

Ocurre cuando el paso que da el algoritmo es tan largo que se pasa de largo del punto más bajo y cae en la pared de enfrente. En las curvas de nivel, esto se ve como si el punto estuviera rebotando de un lado a otro de forma descontrolada, alejándose del centro en lugar de entrar en él.

Eficiencia Computacional: Si el algoritmo se detiene en la iteración 1000 pero aún Se encuentra lejos del mínimo, ¿qué estrategia es mejor: aumentar el número de iteraciones o ajustar la tasa de aprendizaje? Justifique su respuesta.

La mejor estrategia es ajustar la tasa de aprendizaje, ya que esta es la que indica que tan grandes o pequeños son los pasos que se dan para llegar al mínimo local, viéndolo de esa forma en una distancia X dar pasos muy pequeños implica más tiempo en llegar al destino, y pasos más largos implica menos tiempo en llegar al destino, lo que nos lleva a entender que aumentar el número de iteraciones solo mostrará que tanto se demora en llegar, y si son pasos muy pequeños, necesitará más iteraciones para saber el resultado, lo que causa que aumente el uso de los recursos de cómputo, tiempo y dinero.

Generalización: En un problema de ingeniería con cientos de variables (como la optimización de una cadena de suministro), ¿por qué es peligroso confiar en un único punto de inicio aleatorio?

Es peligroso confiar en un solo inicio porque estos problemas tienen muchos mínimos locales. El algoritmo siempre baja hacia el fondo más cercano, si se empieza en el lugar equivocado, se quedará atrapado en un resultado mediocre creyendo que es el mejor. Iniciar desde diferentes puntos nos permite conocer cual de todos esos mínimos locales es el ideal, es decir el mínimo global.

FASE 3

Parte A

Modelo	Conjunto	MAE	RMSE	R^2
MLPRegressor	Train	47.086	68.547	0.858
MLPRegressor	Test	47.175	69.458	0.8488

Tabla 1 (Fuente Propia)

Diferenciación de Métricas: Explique la diferencia técnica entre el Error Absoluto Medio (MAE) y la Raız del Error Cuadrático Medio (RMSE). ¿Cual de las dos penaliza con mayor severidad los errores grandes (outliers) en las ventas y por qué?
diferenciación de métricas MAE y RMSE
Para evaluar el desempeño de un modelo de regresión, es necesario diferenciar cómo las métricas procesan los errores de predicción. La diferencia técnica entre la raíz del error cuadrático medio (RMSE) y el error absoluto medio (MAE) se explica a continuación:

Error absoluto promedio (MAE)
El MAE se caracteriza por ser el promedio absoluto de los errores, expresados en las mismas unidades que la variable objetivo. Una de sus mayores ventajas técnicas es que brinda una interpretación directa para el negocio (como las unidades vendidas, por ejemplo). El MAE tiene una sensibilidad baja en lo que respecta a los valores atípicos (outliers), porque trata con justicia todos los errores, sin tener en cuenta su magnitud. Su uso es aconsejable para calcular el error operativo promedio de cada día.

La raíz cuadrada del error medio cuadrático (RMSE)
El RMSE equivale a la raíz cuadrada del Error Cuadrático Medio (MSE). Esta métrica, a diferencia del MAE, es muy sensible a los valores atípicos. El RMSE amplifica el efecto de los errores más grandes al elevar las discrepancias al cuadrado antes de promediarlas. Por lo tanto, se la toma en cuenta como una medida de diagnóstico para resguardar el sistema de fallos extremos.
Entre ambas métricas, el **RMSE es el que penaliza con mayor severidad los errores grandes**.
Justificación:
Procedimiento matemático: Como puede verse en la comparación de las curvas de error, el MAE aumenta linealmente mientras que el componente cuadrático del RMSE (MSE) lo hace de manera parabólica. Esto significa que un error grande tiene una influencia desmedida en el resultado final comparado con un error pequeño.

Entorno de aplicación: El análisis de datos sugiere que el empleo de métricas cuadráticas es apropiado cuando los errores grandes se consideran desastrosos. En el caso de las ventas, si se comete un error de predicción a gran escala (un valor atípico), podría generar costos financieros significativos debido al quiebre de stock o a un exceso de existencias. Por ende, el RMSE penaliza estos errores de manera más severa para forzar al modelo a reducirlos.

Diagnóstico de Desempeño: Si el R2 en el conjunto de entrenamiento es significativamente mayor que en el de prueba, ¿qué fenómeno está ocurriendo? Proponga una solución basada en lo aprendido en la Fase 1 del taller.

Cuando esto sucede se da el fenómeno conocido como sobreajuste, lo cual implica que el modelo aprendió tan bien de los datos de entrenamiento que no logra clasificar de una manera óptima los datos de prueba.

La solución para el sobreajuste es la penalización, en este caso se aplica Ridge, la cual asegura que el modelo aprenda la tendencia general y no las irregularidades accidentales ya que el modelo se ve obligado a mantener pesos pequeños y distribuidos, lo que mejora drásticamente su desempeño con datos nuevos.

Interpretación de Residuos: Al observar la gráfica de y_real vs y_pred, ¿se identifica algún patrón de error sistemático (ej. subestimación en ventas altas)?

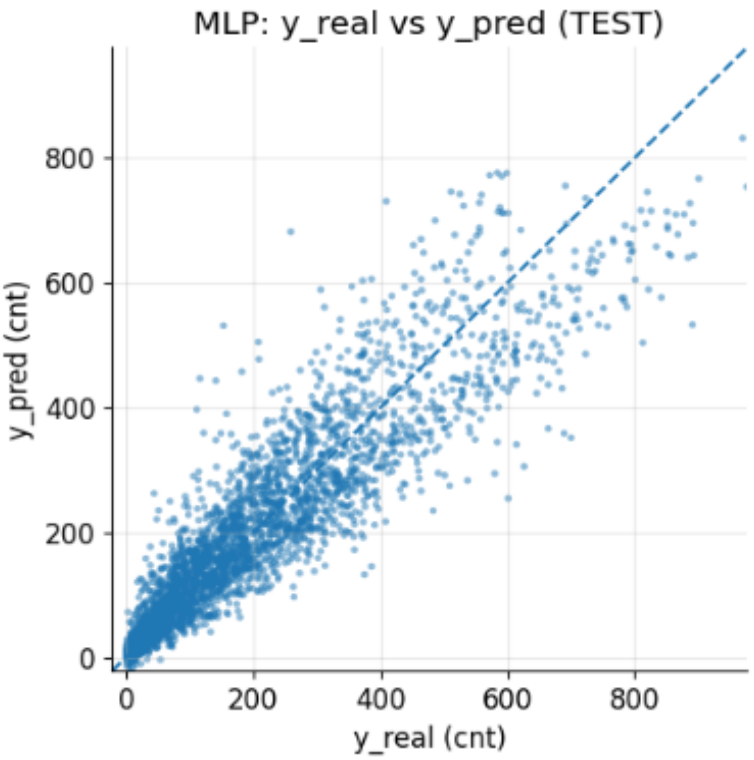

Imagen 5 (Fuente: elaboración propia con base en el notebook del curso.)

Sí se identifica un patrón de error sistemático en el modelo. En la gráfica de dispersión se observa que, para valores de y_real elevados (superiores a 600), los puntos tienden a concentrarse por debajo de la línea de identidad. Esto confirma una subestimación sistemática en los rangos altos, lo que sugiere que el modelo no logra capturar adecuadamente la variabilidad de los eventos pico, presentando un sesgo negativo en las predicciones de mayor magnitud.

Parte B

RED PROFUNDA

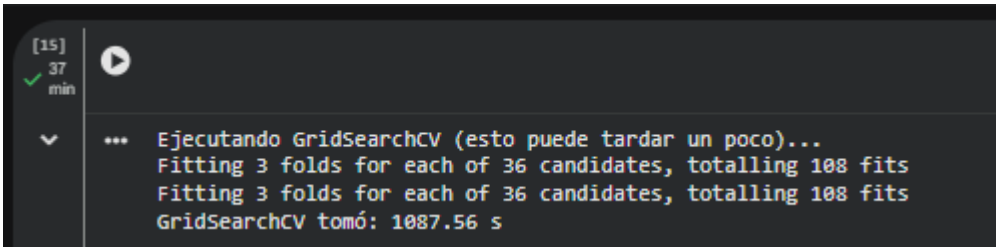

Imagen 6 (Fuente: elaboración propia con base en el notebook del curso.)

Mejores hiperparámetros:

alpha = 1.0
hidden_layer_sizes = (32, 16, 8, 4)
learning_rate_init = 0.001

RMSE CV (aprox): 71.262

Modelo	Conjunto	MAE	RMSE	R^2
MLP (Mejor Modelo)	Train	41.921	61.872	0.885
MLP (Mejor Modelo)	Test	46.021	68.855	0.850

Tabla 2 (Fuente Propia)

El modelo presenta un excelente balance entre ajuste y capacidad de generalización, también muestra un R^2 de 0.885 en entrenamiento frente a un 0.850 en prueba demuestra que la red neuronal aprendió pero evitando el sobreajuste, además la diferencia entre el MAE (46.02) y el RMSE (68.85) indica que, aunque el error típico es bajo, existen algunos errores puntuales de gran magnitud que elevan el promedio cuadrático, indicando que el modelo es robusto y fiable para realizar predicciones con datos nuevos.

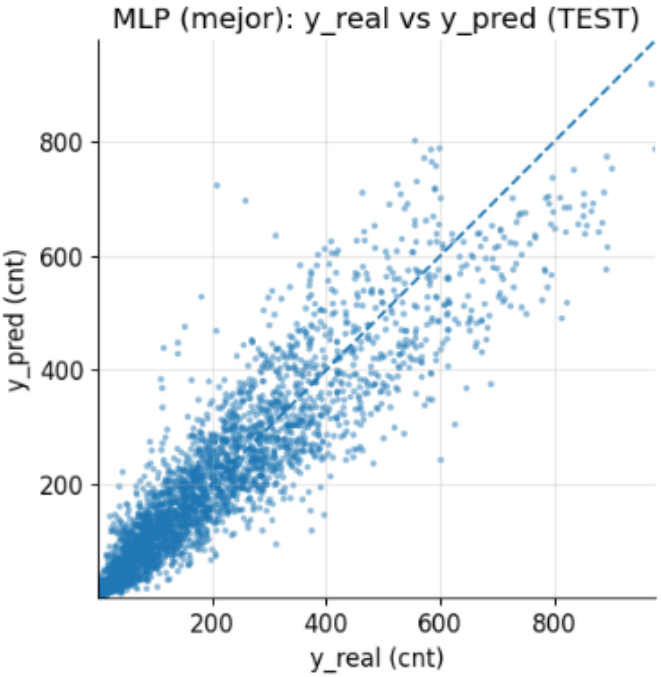

Imagen 7 (Fuente: elaboración propia con base en el notebook del curso.)

Esta gráfica de dispersión muestra la correlación entre los valores verdaderos y las predicciones del modelo, la mayoría de los puntos se agrupan cerca de la línea punteada, lo que indica una buena precisión, sin embargo, se observa una mayor dispersión y una ligera tendencia a la subestimación en los valores superiores a 600, donde los puntos comienzan a quedar por debajo de la línea ideal.

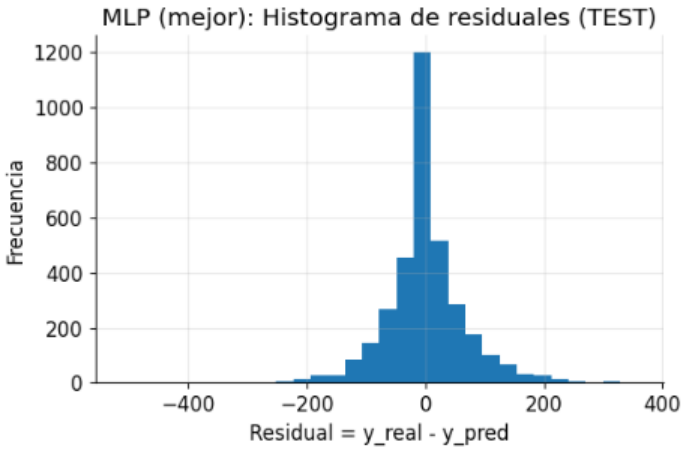

Imagen 8 (Fuente: elaboración propia con base en el notebook del curso.)

Esta gráfica representa la distribución de las desviaciones entre los valores observados y las predicciones del modelo. El hecho de que la mayor frecuencia de datos se concentre en torno al valor **0** indica que el error medio es nulo, lo cual es ideal. La simetría de la campana sugiere que los errores siguen una distribución normal, confirmando que el modelo no presenta un sesgo sistemático hacia la sobreestimación o subestimación, sino que las diferencias son variaciones aleatorias.

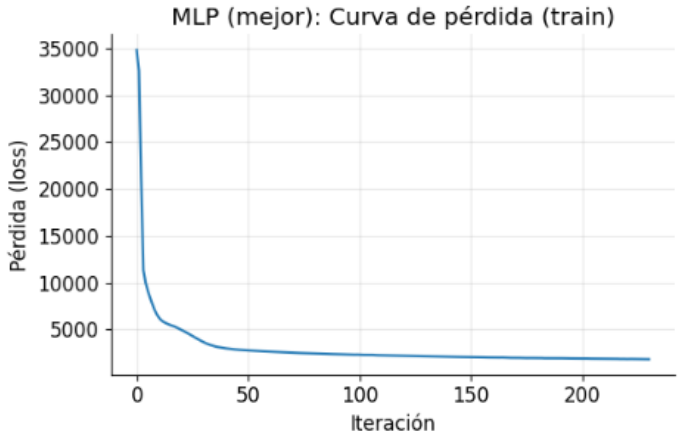

Imagen 9 (Fuente: elaboración propia con base en el notebook del curso.)

Esta curva representa la evolución del error durante el proceso de entrenamiento donde se aprecia un descenso drástico en las primeras 25 iteraciones, luego se estabiliza o converge a partir de la iteración 50, además la suavidad de la curva indica que la tasa de aprendizaje fue adecuada, permitiendo que se encontrara un mínimo de la función de costo de manera eficiente y sin oscilaciones bruscas.

RED ANCHA

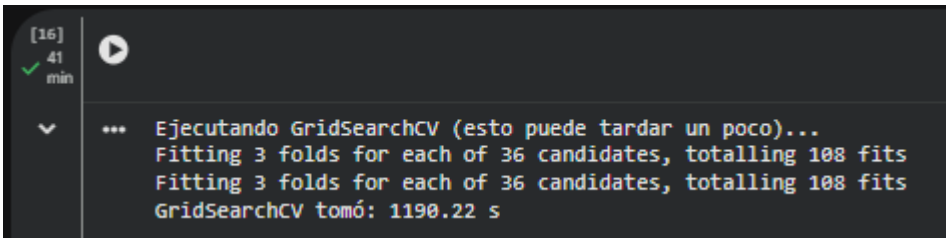

Imagen 10 (Fuente: elaboración propia con base en el notebook del curso.)

Mejores hiperparámetros

alpha = 1.0
hidden_layer_sizes = 64
learning_rate_init = 0.001

RMSE CV (aprox): 72.519

Modelo	Conjunto	MAE	RMSE	R^2
MLP (Mejor Modelo)	Train	47.207	67.030	0.865
MLP (Mejor Modelo)	Test	47.958	67.831	0.855

Tabla 3 (fuente Propia)

El modelo presenta un excelente balance entre ajuste y capacidad de generalización. Un R^2 de 0.885 en entrenamiento frente a un 0.850 en prueba demuestra que la red neuronal aprendió evitando el sobreajuste. La diferencia entre el MAE (46.02) y el RMSE (68.85) indica que, aunque el error típico es bajo, existen algunos errores puntuales de gran magnitud que elevan el promedio cuadrático, indicando que el modelo es robusto y fiable para realizar predicciones con datos nuevos.

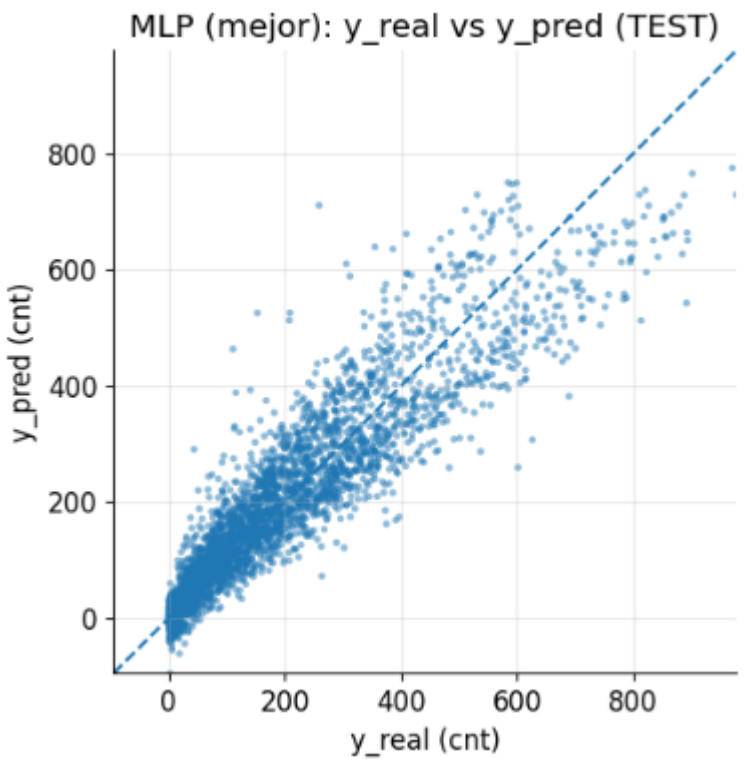

Imagen 11 (Fuente: elaboración propia con base en el notebook del curso.)

Esta gráfica de dispersión muestra la correlación entre los valores verdaderos y las predicciones del modelo, la mayoría de los puntos se agrupan cerca de la línea punteada, lo que indica una buena precisión, sin embargo, se observa una mayor dispersión y una ligera tendencia a la subestimación en los valores superiores a 600, donde los puntos comienzan a quedar por debajo de la línea ideal.

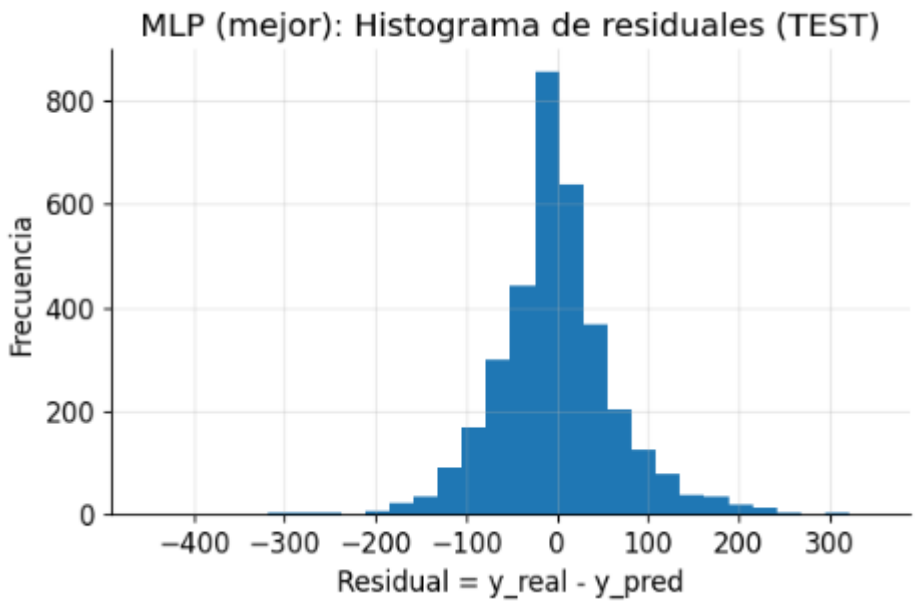

Imagen 12 (Fuente: elaboración propia con base en el notebook del curso.)

Esta gráfica representa la distribución de las desviaciones entre los valores observados y las predicciones del modelo. El hecho de que la mayor frecuencia de datos se concentre en torno al valor 0 indica que el error medio es nulo, lo cual es ideal. La simetría de la campana sugiere que los errores siguen una distribución normal, confirmando que el modelo no presenta un sesgo sistemático hacia la sobreestimación o subestimación, sino que las diferencias son variaciones aleatorias.

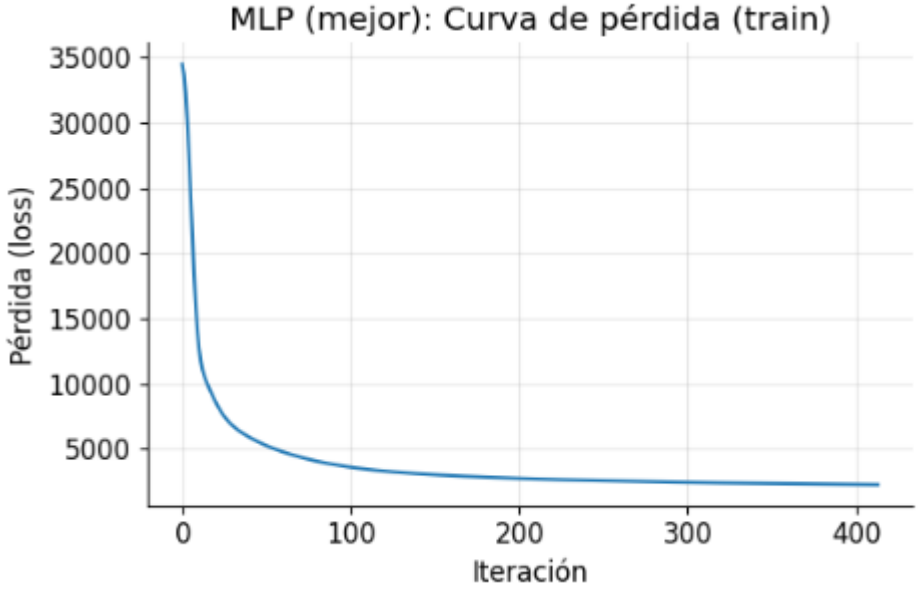

Imagen 13 (Fuente: elaboración propia con base en el notebook del curso.)

Esta curva representa la evolución del error durante el proceso de entrenamiento donde se aprecia un descenso drástico en las primeras 25 iteraciones, luego se estabiliza o converge a partir de la iteración 50, además la suavidad de la curva indica que la tasa de aprendizaje fue adecuada, permitiendo que se encontrara un mínimo de la función de costo de manera eficiente y sin oscilaciones bruscas.

Al comparar ambos modelos, se observa que la Red Ancha y la Red Profunda alcanzan un desempeño prácticamente idéntico en términos de métricas, con un R^2 de 0.850 en el conjunto de prueba y un RMSE de 68.8, esto indica que, para este dataset específico, aumentar la profundidad de la arquitectura (añadiendo más capas como en la red profunda) no generó una ventaja competitiva sobre una estructura más plana pero con mayor capacidad en sus capas.
Ambas redes lograron un equilibrio óptimo de generalización, manteniendo una brecha mínima respecto al entrenamiento y presentando los mismos patrones de error, como la ligera subestimación en valores altos y una distribución de residuales normalizada, en conclusión, ambas arquitecturas fueron igualmente efectivas.

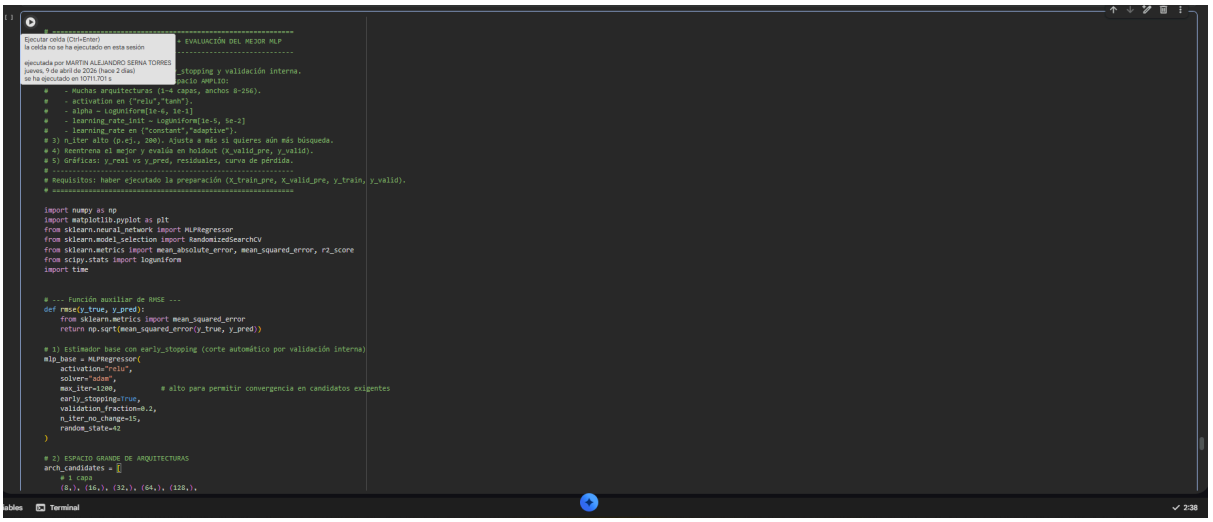

Imagen 14(Fuente: elaboración propia con base en el notebook del curso.)

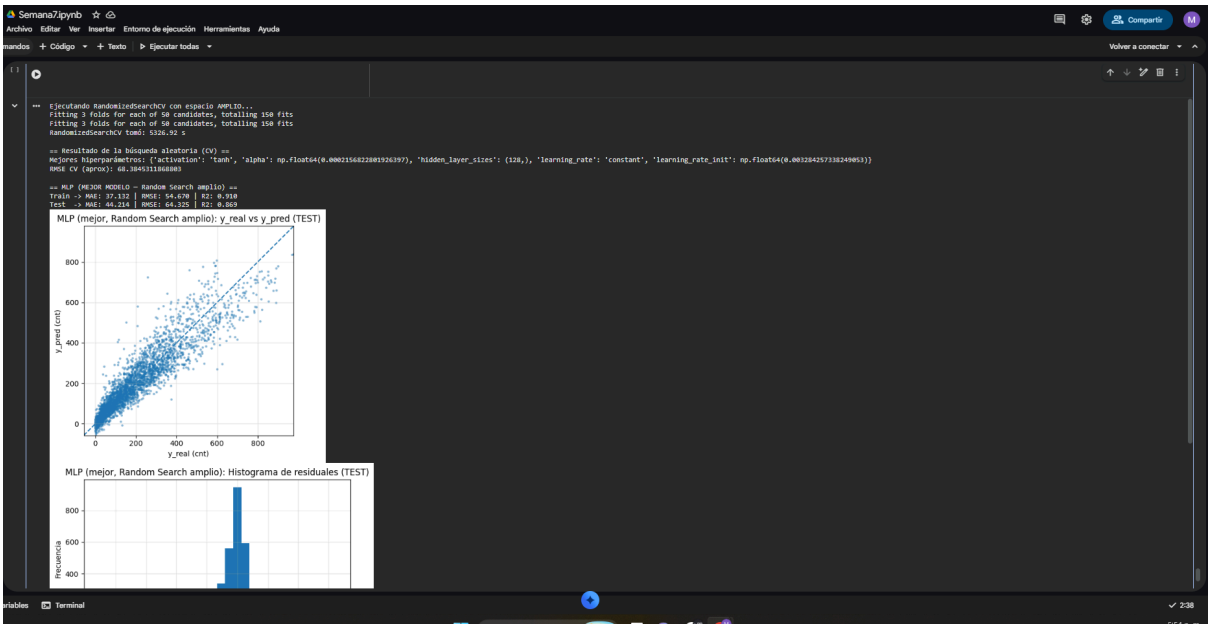

Imagen 15 (Fuente: elaboración propia con base en el notebook del curso.)

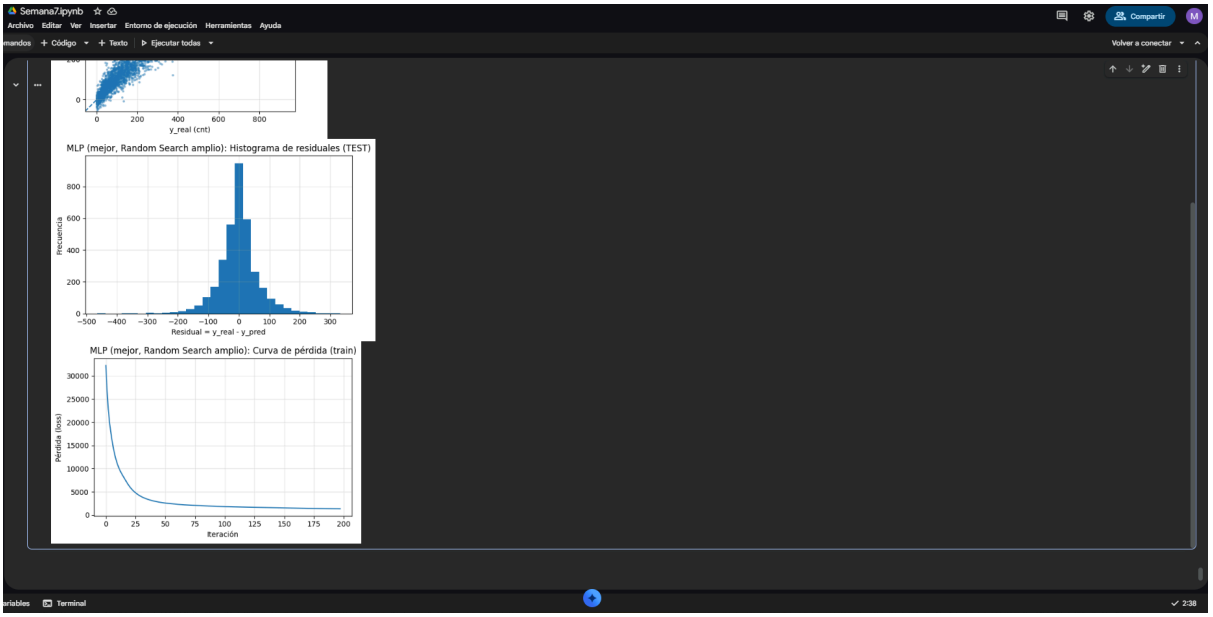

Imagen 16 (Fuente: elaboración propia con base en el notebook del curso.)

FASE 4

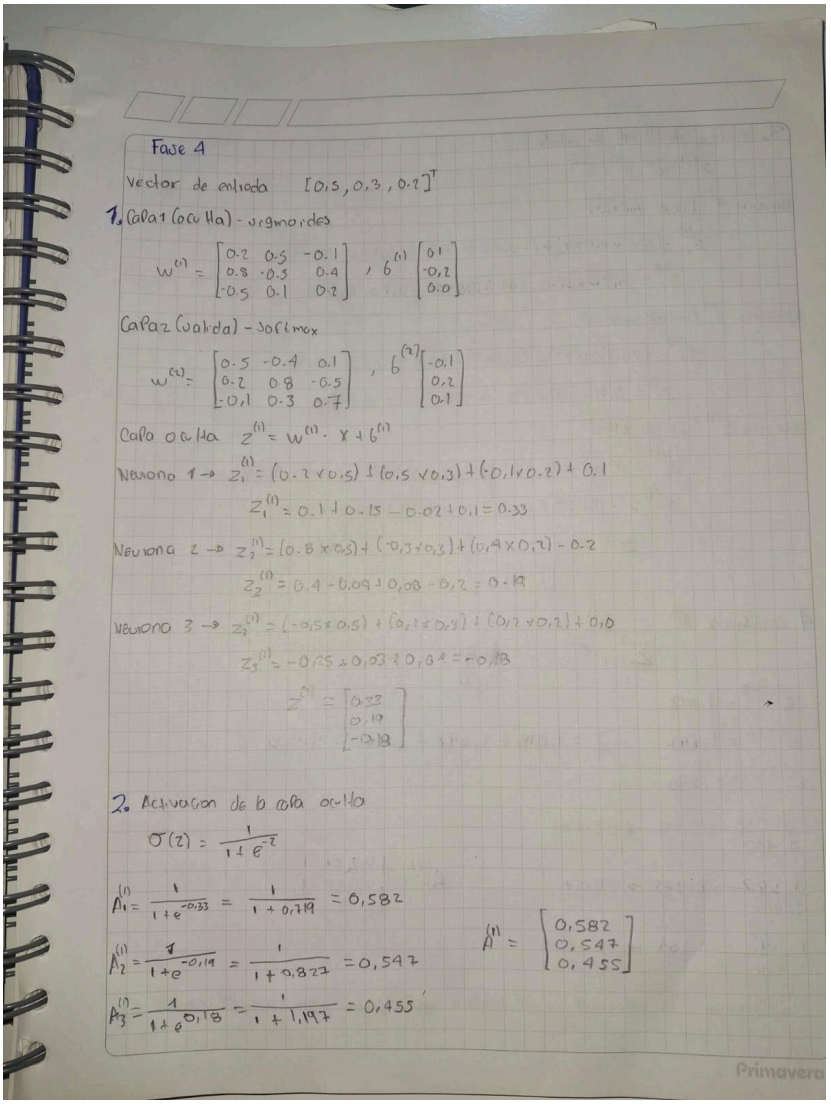

Fase 4

Vector de entrada $[0.5, 0.3, 0.2]^T$

1. Capa 1 (oculta) - sigmoides

$$W^{(1)} = \begin{bmatrix} 0.2 & 0.5 & -0.1 \\ 0.8 & -0.3 & 0.4 \\ -0.5 & 0.1 & 0.2 \end{bmatrix}, \quad b^{(1)} \begin{bmatrix} 0.1 \\ -0.2 \\ 0.0 \end{bmatrix}$$

Capa 2 (salida) - Softmax

$$W^{(2)} = \begin{bmatrix} 0.5 & -0.4 & 0.1 \\ 0.2 & 0.8 & -0.5 \\ -0.1 & 0.3 & 0.7 \end{bmatrix}, \quad b^{(2)} \begin{bmatrix} -0.1 \\ 0.2 \\ 0.1 \end{bmatrix}$$

Capa oculta $z^{(1)} = W^{(1)} \cdot x + b^{(1)}$

Neurona 1 → $z_1^{(1)} = (0.2 \times 0.5) + (0.5 \times 0.3) + (-0.1 \times 0.2) + 0.1$

$z_1^{(1)} = 0.1 + 0.15 - 0.02 + 0.1 = 0.33$

Neurona 2 → $z_2^{(1)} = (0.8 \times 0.5) + (-0.3 \times 0.3) + (0.4 \times 0.2) - 0.2$

$z_2^{(1)} = 0.4 - 0.09 + 0.08 - 0.2 = 0.19$

Neurona 3 → $z_3^{(1)} = (-0.5 \times 0.5) + (0.1 \times 0.3) + (0.2 \times 0.2) + 0.0$

$z_3^{(1)} = -0.25 + 0.03 + 0.04 = -0.18$

$$z^{(1)} = \begin{bmatrix} 0.33 \\ 0.19 \\ -0.18 \end{bmatrix}$$

2. Activación de la capa oculta

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

$$A_1^{(1)} = \frac{1}{1 + e^{-0.33}} = \frac{1}{1 + 0.719} = 0.582$$

$$A_2^{(1)} = \frac{1}{1 + e^{-0.19}} = \frac{1}{1 + 0.827} = 0.547$$

$$A_3^{(1)} = \frac{1}{1 + e^{0.18}} = \frac{1}{1 + 1.197} = 0.455$$

$$A^{(1)} = \begin{bmatrix} 0.582 \\ 0.547 \\ 0.455 \end{bmatrix}$$

Imagen 17 (Fuente: elaboración propia con base en el notebook del curso.)

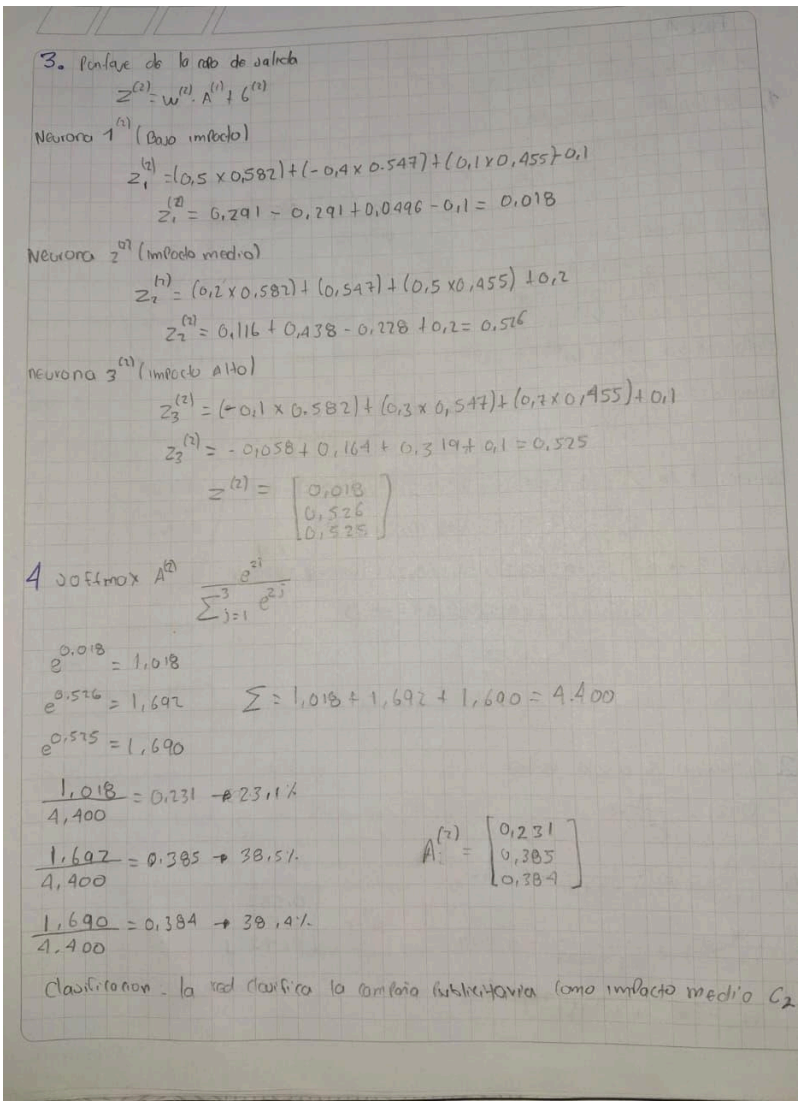

3. Puntaje de la capa de salida

$$Z^{(2)} = W^{(2)} \cdot A^{(1)} + b^{(2)}$$

Neurona $1^{(2)}$ (Bajo impacto)

$$Z_1^{(2)} = (0,5 \times 0,582) + (-0,4 \times 0.547) + (0,1 \times 0,455) + 0,1$$

$$Z_1^{(2)} = 0,291 - 0,291 + 0,0496 - 0,1 = 0,018$$

Neurona $2^{(2)}$ (Impacto medio)

$$Z_2^{(2)} = (0,2 \times 0,582) + (0,547) + (0,5 \times 0,455) + 0,2$$

$$Z_2^{(2)} = 0,116 + 0,438 - 0,228 + 0,2 = 0,526$$

neurona $3^{(2)}$ (impacto alto)

$$Z_3^{(2)} = (-0,1 \times 0.582) + (0,3 \times 0,547) + (0,7 \times 0,455) + 0,1$$

$$Z_3^{(2)} = -0,058 + 0,164 + 0,319 + 0,1 = 0,525$$

$$Z^{(2)} = \begin{bmatrix} 0,018 \\ 0,526 \\ 0,525 \end{bmatrix}$$

4 Softmax $A^{(2)}$ $\dfrac{e^{z_i}}{\sum_{j=1}^{3} e^{z_j}}$

$e^{0.018} = 1,018$

$e^{0.526} = 1,692$ $\quad \sum = 1,018 + 1,692 + 1,690 = 4.400$

$e^{0,525} = 1,690$

$\dfrac{1,018}{4,400} = 0,231 \rightarrow 23,1\%$

$\dfrac{1,692}{4,400} = 0.385 \rightarrow 38,5\%$ $\quad A^{(2)} = \begin{bmatrix} 0,231 \\ 0,385 \\ 0,384 \end{bmatrix}$

$\dfrac{1,690}{4,400} = 0,384 \rightarrow 38,4\%$

Clasificación: la red clasifica la campaña publicitaria como impacto medio C_2

Imagen 18 (Fuente: elaboración propia con base en el notebook del curso.)

Interpretación de Resultados: Según las probabilidades obtenidas, ¿en qué categoría se clasifica la red a esta campaña publicitaria?

La red neuronal clasifica la campaña publicitaria en la categoría Impacto Medio (C2). Esto se determina porque, tras aplicar la función Softmax, la probabilidad asignada a C2 fue del 38.5%, superando ligeramente a C3 con 38.4% y claramente a C1 con 23.1%.

Aunque las probabilidades entre C2 y C3 son muy cercanas, el modelo elige la clase con mayor valor numérico, lo que en este caso es Impacto Medio. Esta decisión refleja que la combinación de inversión en TV, Radio y Newspaper genera un efecto moderado sobre las ventas.

Funcionamiento de Activación: ¿Por qué utilizamos Softmax en la última capa en lugar de una función lineal o una sigmoide simple? Explique en términos de la suma de las probabilidades.

Softmax se utiliza porque garantiza que la suma de todas las probabilidades de salida sea exactamente 1, formando así una distribución de probabilidad válida. Esto es esencial en problemas de clasificación multiclase, donde cada ejemplo debe pertenecer a una única categoría con cierto nivel de confianza.

En contraste, la función sigmoide aplicada individualmente a cada neurona produce valores entre 0 y 1, pero su suma puede ser mayor o menor que 1, lo que impide interpretarlas como probabilidades. La función lineal ni siquiera restringe las salidas al rango [0,1], haciéndola inapropiada para clasificación.

Rol del Bias: ¿Que sucederá con la capacidad de representación de la red si todos los vectores de sesgo (b) fueran cero?

Si todos los sesgos fueran cero, la red perdería significativamente su capacidad de representación, ya que todas las funciones aprendidas estarían forzadas a pasar por el origen del espacio de características. Esto limita drásticamente los patrones que la red puede aprender, especialmente aquellos que requieren umbrales o desplazamientos.

Sin sesgos, una neurona no podría aprender condiciones del tipo "activar si la entrada supera un valor X", porque no habría forma de desplazar la función de activación. En la práctica, eliminar los sesgos reduce el modelo a un subconjunto muy restringido de funciones, lo que generalmente lleva a un rendimiento mucho más pobre en tareas del mundo real.

FASE 5

Parte A

Análisis de Pesos: Si el modelo indica que los errores en la Clase 1 (Fallo) pesaran aproximadamente 14.7 veces más que en la Clase 0, ¿qúe intenta corregir el algoritmo al configurar el parámetro class weight durante el entrenamiento?

El uso de class weight busca compensar que hay muchos más casos de “no falla” que de fallos. Si no se hiciera este ajuste, el modelo podría simplemente predecir casi siempre “no falla” y aun así obtener buena exactitud, pero sería poco útil porque no detectaría los fallos reales. Al darle mucho más peso a la Clase 1, se castiga más cuando el modelo se equivoca al no detectar un fallo, haciendo que preste más atención a estos casos y mejore su capacidad para identificarlos, que es lo más importante en este tipo de problema.

La Trampa de la Exactitud: Explique por que en este caso un Accuracy del 95 % podrıa considerarse un resultado deficiente para la gestíon de mantenimiento si el modelo no logra detectar los fallos reales.

Un accuracy del 95% puede ser engañoso porque los fallos ocurren muy pocas veces. El modelo podría decir siempre “no falla” y aun así acertar casi todo, pero no estaría detectando los fallos reales. En mantenimiento predictivo esto es un problema, porque lo importante es identificar los fallos a tiempo, no solo tener un porcentaje alto de aciertos.

- **Interpretación de la Matriz de Confusión**

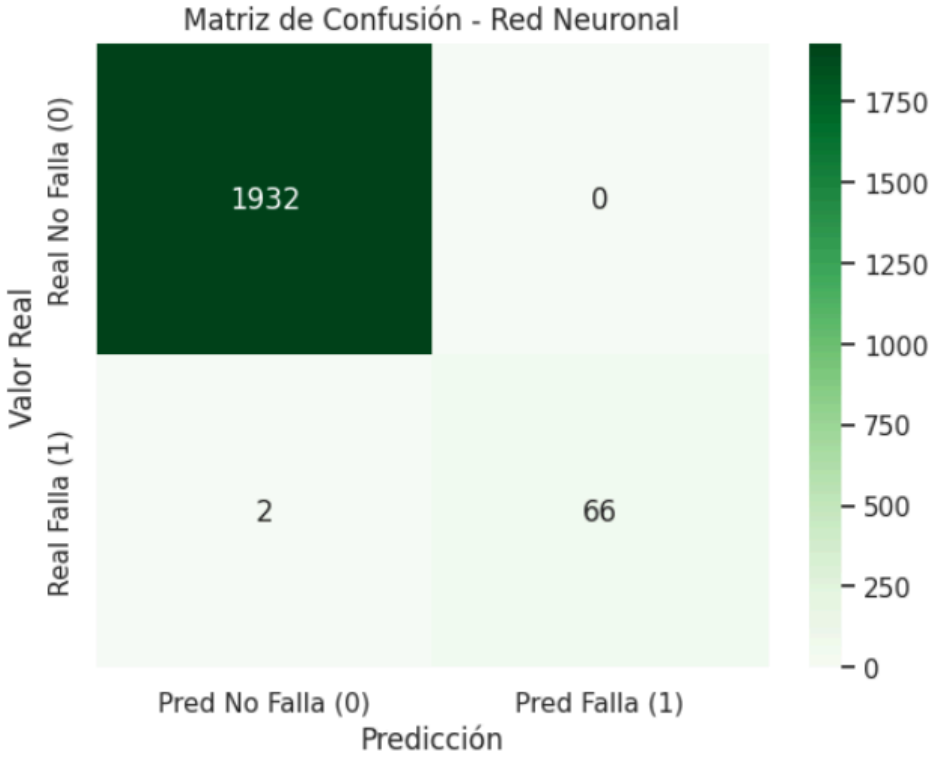

Imagen 19 (Fuente: elaboración propia con base en el notebook del curso.)

1. Precisión $\frac{TP}{TP+FP}$ ¿Qué tan confiable es el modelo cuando emite una alerta de falla?

$\frac{66}{66+0} = 1$ Cada vez que el modelo predice “fallo”, siempre acierta.

2. **Recall (Sensibilidad): $\frac{TP}{TP+NP}$ ¿Qué porcentaje de los fallos reales totales logró capturar el modelo?**

$\frac{66}{66+2} = 0.97$ Detecta casi todos los fallos reales.

3. Costo Total de Error: Calcule el impacto económico mensual del modelo utilizando la fórmula: Costo = (FN × 5000) + (FP × 200)

Costo=(2×5000)+(0×200)=10000

El costo total de 10,000 USD representa las pérdidas generadas por los errores del modelo. En este caso, proviene de 2 fallos no detectados (FN), que son los más costosos. Aunque el modelo tiene buen desempeño, estos errores siguen teniendo un impacto económico importante.

Parte B

Trade-off entre Recall y Precisión: En el contexto de evitar paradas de línea críticas, ¿preferiría usted un modelo con un Recall del 98% pero una precisión del 60%, o viceversa? Justifique su respuesta basándose en los costos calculados anteriormente.

En el sector manufacturero, el costo de oportunidad de un "Falso Negativo" (una falla no detectada que detiene la producción) es masivo comparado con el costo de un "Falso Positivo" (una inspección preventiva que resulta innecesaria). Un Recall del 98% nos asegura que prácticamente ninguna avería grave pasará desapercibida. Aunque una precisión del 60% implique realizar verificaciones en equipos que aún funcionan correctamente, este costo operativo es marginal frente a las pérdidas económicas por inactividad, daños colaterales en la maquinaria y retrasos en la cadena de suministros.

Curva de Aprendizaje: Observe la gráfica de loss (pérdida) y accuracy durante el entrenamiento. ¿Considera que 30 épocas son suficientes para que el modelo converja? ¿Qué sucede con el error de validación comparado con el de entrenamiento?

Se consideran suficientes siempre que la curva de pérdida haya alcanzado una meseta (asíntota) clara, indicando que el modelo ya extrajo el máximo conocimiento de los datos. Si la pendiente se mantiene pronunciada al llegar a la época 30, el modelo aún requiere más iteraciones para converger.
Lo ideal es que el error de entrenamiento y el de validación desciendan de forma paralela. Si el error de entrenamiento continúa bajando mientras que el de validación se estanca o incrementa, estamos ante un caso de sobreajuste, donde el modelo está memorizando el ruido de la muestra en lugar de aprender patrones generales.

Conclusión Final del Taller: Tras recorrer desde la regresión analítica hasta la clasificación con redes neuronales, ¿cómo puede el uso de métricas avanzadas (como el Recall) transformar la rentabilidad de una empresa de manufactura?

Al integrar redes neuronales y optimizar el Recall, la empresa no solo busca "acertar predicciones", sino gestionar proactivamente el riesgo financiero. Esta transformación permite reducir drásticamente los costos ocultos por paradas no programadas y desperdicio de recursos. En conclusión, la analítica avanzada otorga a la manufactura la capacidad de operar con una mayor previsibilidad, garantizando la continuidad del negocio y optimizando el retorno de inversión en tecnologías de industria 4.0.